

DETECÇÃO AUTOMÁTICA DE CASOS DE COVID-19 A PARTIR DE IMAGENS DE RADIOGRAFIA DE TÓRAX

SOARES, César P.¹

SOARES, Lucas P.²

RESUMO

Nos últimos meses o mundo foi surpreendido com o rápido avanço da COVID-19. Para o enfrentamento desta doença e minimização dos seus impactos socioeconômicos, além da vigilância e tratamento, o diagnóstico se apresenta como um procedimento crucial. No entanto, a realização deste é obstaculizada pela demora e pelo acesso limitado aos testes laboratoriais. Demandando, assim, novas estratégias para realizar a triagem de casos. Nesse cenário, modelos de aprendizado profundo de máquina (*deep learning*) estão sendo propostos como uma possível opção para auxiliar o processo de diagnóstico a partir de imagens de radiografia de tórax – raio X e tomografia computadorizada. Assim, este projeto de pesquisa tem como objetivo automatizar o processo de detecção de casos de COVID-19 a partir de imagens de radiografia de tórax, utilizando redes neurais convolucionais (RNC) por meio de técnicas de aprendizado profundo. Os resultados podem contribuir para a ampliação do acesso a outras formas de detecção da COVID-19 e para acelerar o processo de identificação desta enfermidade. Todos os bancos de dados utilizados, os códigos construídos e os resultados obtidos a partir do treinamento dos modelos, serão disponibilizados para acesso livre. Esta ação tem o objetivo de facilitar o envolvimento de outros pesquisadores no processo de aperfeiçoamento destes modelos, já que isto pode contribuir para a melhora dos resultados e, consequentemente, o avanço no enfrentamento à COVID-19.

¹ Doutorando em Saúde Global e Sustentabilidade na Faculdade de Saúde Pública da Universidade de São Paulo (USP). Página e contato: <https://cpscesar.github.io/> e cpscesar@usp.br

² Mestrando em Recursos Minerais e Meio Ambiente no Instituto de Geociências da Universidade de São Paulo (USP). Página e contato: <https://lpsmlgeobr.github.io/> e lpsoares@usp.br

1. INTRODUÇÃO

Nos últimos meses o mundo foi surpreendido com o rápido avanço da Sars-Cov-2 (COVID-19). Atualmente, ante a ampla disseminação deste vírus em todos os continentes, a Organização Mundial da Saúde (OMS) declarou que vivemos uma pandemia desta enfermidade.

Para o enfrentamento desta doença e minimização dos seus impactos socioeconômicos, além da vigilância e tratamento, o diagnóstico se apresenta como um procedimento crucial (BINNICKER, 2020). No entanto, a realização deste é obstaculizada pela demora e pelo acesso limitado aos testes laboratoriais disponíveis para detectar a COVID-19³ (WHO, 2020), demandando, assim, novas estratégias para realizar a triagem de casos.

Estudos na área estão apontando para a existência de indicadores específicos na radiografia de tórax de indivíduos infectados pelo vírus Sars-Cov-2 (MING-YEN, 2020). Fato que possibilitaria a utilização destas imagens no processo de diagnóstico da COVID-19 (AI, 2020), ampliando o acesso a outras formas de detecção da enfermidade e acelerando o seu processo de identificação.

Nesse cenário, modelos de aprendizado profundo de máquina (*deep learning*) estão sendo propostos como uma possível opção para auxiliar o processo de diagnóstico. Em específico, esta técnica surge com o intuito de tornar automática a detecção de casos de COVID-19 a partir de imagens de radiografia de tórax – raio X e tomografia computadorizada (GOZES, 2020; XU, 2020; WANG; WONG, 2020).

Nesse sentido, este projeto de pesquisa⁴ propõe o treinamento de modelos, a partir do aprendizado profundo de máquina, capazes de detectar de forma precisa a presença da COVID-19 a partir de imagens de radiografia de tórax.

De forma complementar, mas não menos importante, este projeto, com o intuito de tornar público os resultados obtidos e os dados utilizados, irá disponibilizar os códigos construídos para realizar o treinamento dos modelos, os bancos de dados elaborados pelos autores e as fontes de dados externas. Tal ação visa facilitar o envolvimento de outros pesquisadores no processo de aperfeiçoamento destes modelos, já que isto pode contribuir para a melhora dos resultados e, conseqüentemente, o avanço no enfrentamento à COVID-19^{5, 6}.

³ O *Reverse-Transcriptase Polymerase Chain Reaction* (RT-PCR) é considerado o método padrão de referência para a realização do diagnóstico de infecção por COVID-19 (COLUMBUS; BRUST; ARROLIGA, 2020).

⁴ A pesquisa já se encontra em andamento desde o dia 06/04/2020.

⁵ Informações sobre as bases de dados utilizadas estão disponíveis na seção referente à metodologia.

⁶ Para acessar o blog com atualizações semanais sobre os resultados e os modelos utilizados, acessar: <https://deepdados.github.io/>

2. OBJETIVO

Automatizar o processo de detecção de casos de COVID-19 a partir de imagens de radiografia de tórax, utilizando redes neurais convolucionais (RNC) por meio de técnicas de aprendizado profundo (*deep learning*).

3. METODOLOGIA

O *deep learning* é uma técnica de aprendizagem de máquina que, por meio de redes neurais, busca descobrir de maneira autônoma – isto é, sem programação explícita – regras e parâmetros de um conjunto de dados, com o objetivo de fornecer uma representação adequada para um determinado problema. O termo “aprendizado profundo” deriva da grande quantidade de camadas escondidas (*hidden layers*) entre a camada de entrada e a de saída da rede neural.

Neste trabalho, modelos de redes neurais de convolução⁷ serão treinados com base no processo de aprendizado supervisionado. Isto é, além dos dados de treinamento, referentes às imagens de raio X e tomografia computadorizada de tórax, o resultado esperado também servirá de *input* para o modelo.

O treinamento completo (*end-to-end*) de uma rede usualmente necessita de uma grande quantidade de imagens para obter bons resultados, o que muitas vezes não é viável. Neste projeto, com intuito de observar a necessidade deste fator, os autores irão comparar os resultados de modelos treinados apenas com a quantidade de imagens disponíveis, com os resultados de modelos treinados utilizando a técnica de transferência de conhecimento (*transfer learning*), uma vez que os *datasets* possuem poucas imagens de COVID-19. Além disso, caso a quantidade de imagens não seja suficiente para treinar o modelo, serão empregadas técnicas de *data augmentation*.

Para a construção de uma RNC, devem ser considerados aspectos referentes a sua arquitetura, seus parâmetros e estatística de avaliação dos resultados. Especificamente, serão utilizadas as arquiteturas VGG-16⁸, *Residual Networks* (ResNet)⁹ e Xception¹⁰. Para a técnica de transferência de conhecimento, serão utilizados os pesos obtidos através do *dataset* ImageNet¹¹. Os autores deste projeto utilizarão inicialmente os seguintes parâmetros¹²: função

⁷ Estes modelos têm apresentado resultados superiores em problemas de classificação de imagens (LECUN; BENGIO, 1995).

⁸ Website da arquitetura: <https://arxiv.org/abs/1409.1556>

⁹ Website da arquitetura: <https://arxiv.org/abs/1512.03385>

¹⁰ Website da arquitetura: <https://arxiv.org/abs/1610.02357>

¹¹ Website do ImageNet: <http://www.image-net.org/>


¹² Tais parâmetros (*hyperparameters*) serão ajustados ao longo do processo de treinamento da rede visando obter a maior acurácia.

de otimização Adam; *Learning rate* = 0,001; *Epochs* = 100; *Batch size* = 8; *Loss function* = *binary cross-entropy*. Os resultados serão avaliados com base na acurácia. As redes serão treinadas utilizando a linguagem de programação Python a partir da biblioteca TensorFlow¹³.

Por fim, a construção do banco de dados terá o intuito de maximizar a quantidade de imagens de treino. Para tanto, serão utilizadas duas fontes distintas: uma contendo imagens de raio X e tomografias computadorizadas de tórax de indivíduos infectados com COVID-19 ($n = 131$)¹⁴ (COHE; MORRISON; DAO, 2020) e a outra, contendo o mesmo tipo de imagem, mas de pulmões de indivíduos sem nenhuma infecção ($n = 101$)¹⁵ (KERMANY; ZHANG; GOLDBAUM, 2018). A escolha destes dados se justifica pela possibilidade de acesso livre aos bancos de imagem.

4. RESULTADOS PRELIMINARES

Os resultados preliminares, apoiando-se na técnica de transferência de conhecimento, foram obtidos utilizando a arquitetura VGG-16. Abaixo foi anexada uma matriz de confusão com o intuito de expor a acurácia do modelo ao ser testado com 55 imagens retiradas aleatoriamente do banco de dados. Ressalta-se que estas imagens não foram utilizadas no treinamento do modelo.



Fonte: elaborado pelos autores deste projeto

¹³ Website da biblioteca: <https://www.tensorflow.org/>

¹⁴ Imagens disponibilizadas no site: <https://github.com/ieee8023/covid-chestxray-dataset>

¹⁵ Imagens disponibilizadas no site: <https://data.mendeley.com/datasets/rscbjbr9sj/2>

O modelo errou apenas uma classificação entre as 55 imagens utilizadas para o teste, apresentando uma acurácia de 98%. A matriz de confusão mostra que, dentre o total de imagens, 58% (n = 32) representam verdadeiros positivos, 40% (n = 22) verdadeiros negativos, 1,8% (n = 1) falsos negativos e 0% (n = 0) falsos positivos.

Na figura abaixo foram expostas as imagens utilizadas para o teste do modelo. Os “Labels” (*Label Predict* e *Label Correct*) que apresentam o mesmo nome indicam que o modelo acertou a predição. Exemplo: *Label Predict* = COVID e *Label Correct* = COVID. A imagem classificada incorretamente foi destacada com o contorno vermelho.

Resultados da rede VGG16



Fonte: elaborado pelos autores deste projeto

A partir dos resultados preliminares é possível notar que o modelo apresenta uma acurácia elevada para classificar os pulmões normais e com COVID-19. Com o intuito de aperfeiçoar o desempenho da rede, os próximos modelos realizarão treinamentos com imagens de pulmões que apresentam outras infecções¹⁶.

5. REFERÊNCIAS BIBLIOGRÁFICAS

AI, Tao et al. Correlation of chest CT and RT-PCR testing in coronavirus disease 2019 (COVID-19) in China: a report of 1014 cases. *Radiology*, 2020. Disponível em: <https://doi.org/10.1148/radiol.2020200642>

BINNICKER, Matthew. Emergence of a Novel Coronavirus Disease (COVID-19) and the Importance of Diagnostic Testing: Why Partnership between Clinical Laboratories, Public Health Agencies, and Industry Is Essential to Control the Outbreak. *Clinical Chemistry*, hvaa071, 2020. Disponível em: <https://doi.org/10.1093/clinchem/hvaa071>

COHEN, Joseph; MORRISON, Paul; DAO, Lan. COVID-19 Image Data Collection. *arXiv:2003.11597*, 2020.

COLUMBUS, Cristie; BRUST, Karen; ARROLIGA, Alejandro. 2019 novel coronavirus: an emerging global threat. *Baylor University Medical Center Proceedings*, v.33, n.2, 2020. Disponível em: <https://doi.org/10.1080/08998280.2020.1731272>

GOZES, Ophir et al. Rapid AI development cycle for the coronavirus (COVID-19) pandemic: initial results for automated detection & patient monitoring using deep learning CT image analysis. *arXiv:2003.05037*, 2020.

KERMANY, Daniel; ZHANG, Kang; GOLDBAUM, Michael. Labeled Optical Coherence Tomography (OCT) and Chest X-Ray Images for Classification. *Mendeley Data*, v.2, 2018. Disponível em: <http://dx.doi.org/10.17632/rscbjbr9sj.2>

LECUN, Yann; BENGIO, Yoshua. Convolutional Networks for Images, Speech, and Time-Series. *The handbook of brain theory and neural networks*, v. 3361, n. 10, 1995.

¹⁶ Os próximos resultados serão disponibilizados semanalmente no blog dos autores deste projeto: <https://deepdados.github.io/>

MING-YEN, Ng et al. Imaging profile of the COVID-19 infection: radiologic findings and literature review. *Radiology: Cardiothoracic Imaging*, v.2(1), 2020. Disponível em: <https://doi.org/10.1148/ryct.2020200034>

WANG, Linda; WONG, Alexander. COVID-Net: a tailored deep convolutional neural network design for detection of COVID-19 cases from chest radiography images. *arXiv:2003.09871*, 2020.

WHO, World Health Organization. *Laboratory testing strategy recommendations for COVID-19*. Interim guidance 21, 2020. Disponível em: https://apps.who.int/iris/bitstream/handle/10665/331509/WHO-COVID-19-lab_testing-2020.1-eng.pdf

XU, Xiaowei et al. Deep learning system to screen coronavirus disease 2019 pneumonia. *arXiv:2002.09334*, 2020.